Note de Transparence – AI Cyber Human Shield

Algorithmes choisis :

- **Règles simples** : mots suspects (« Buongiorno», « urgent », « motdepasse », « gagner TND »), liens suspects, tentatives multiples.
- **Scoring de risque** : chaque critère donne un score ; plus il est élevé, plus le mail est suspect. (+20pts , +15pts, + 10pts..)
- **IA LLM + RAG** : pour expliquer les alertes et analyser des modèles de menace connus.
- **Explainable AI (XAI)** : chaque alerte a une justification lisible et tous les logs sont traçables.

Provenance et gestion des datasets :

- Emails simulés (phishing / safe), inspirés de cas réels en Tunisie.
- Combinaison de plusieurs critères pour limiter les faux positifs.
- L'humain valide toutes les alertes importantes.
- Les règles peuvent évoluer avec les retours des utilisateurs.

Mesures de défense de l'IA :

- **Protection contre les injections malveillantes :** seules les données collectées par l'extension/interface sont analysées.
- **Aucune action automatique critique :** l'IA propose une action, l'humain décide.
- **Souveraineté des données :** tout est traité localement, aucun transfert externe.

Human-in-the-loop :

- L'utilisateur est toujours au centre.
- L'IA propose, l'humain décide, pour garantir confiance et contrôle.